



Projetos Finais

Projeto 1: Testes de Hipóteses em Saúde - Segurança de Fármacos

A empresa farmacêutica GlobalXYZ acabou de concluir um ensaio clínico randomizado. Para promover transparência e reprodutibilidade dos resultados, ela (GlobalXYZ) disponibilizou o conjunto de dados para sua organização, uma instituição sem fins lucrativos com foco principal em segurança de medicamentos.

O conjunto de dados fornecido inclui cinco eventos adversos, dados demográficos, sinais vitais etc. Sua organização está especialmente interessada nas reações adversas ao medicamento. Ela quer saber se as reações adversas, caso existam, ocorrem em proporções significativas. Você foi convidado a explorar os dados e responder a algumas perguntas.

O conjunto de dados `drug_safety.csv` foi obtido a partir do conjunto `safety.rda`, disponível em [Hbiostat](#), cortesia do Department of Biostatistics da Vanderbilt University. Ele contém cinco eventos adversos: dor de cabeça, dor abdominal, dispepsia, infecção do trato respiratório superior, doença pulmonar obstrutiva crônica (DPOC), além de dados demográficos, sinais vitais, medidas laboratoriais etc. A razão entre observações do medicamento e do placebo é de 2 para 1.

Para este projeto, o conjunto de dados foi modificado para refletir a presença e ausência de eventos adversos `adverse_effects` e o número de eventos adversos em um mesmo indivíduo `num_effects`.

As colunas no conjunto de dados modificado são:

Coluna	Descrição
sex	O gênero do indivíduo
age	A idade do indivíduo
week	A semana do teste do medicamento
trx	Os grupos de tratamento (Drug) e controle (Placebo)
wbc	A contagem de glóbulos brancos
rbc	A contagem de glóbulos vermelhos
adverse_effects	A presença de pelo menos um evento adverso
num_effects	O número de eventos adversos experimentados por um indivíduo

Sua organização pediu que você explorasse e respondesse a algumas perguntas com base nos dados coletados. Veja as instruções do projeto.

Instruções

- 1) Determine se a proporção de efeitos adversos difere significativamente entre os grupos Drug e Placebo, salvando o p-value em uma variável chamada `two_sample_p_value`.
- 2) Descubra se o número de efeitos adversos é independente dos grupos de tratamento e controle, salvando em uma variável chamada `num_effects_p_value` contendo um p-value.
- 3) Verifique se há diferença significativa entre as idades dos grupos Drug e Placebo, armazenando o p-value do seu teste em uma variável chamada `age_group_effects_p_value`.

Como abordar o projeto

- 1) Z-test de proporções para duas amostras: Determine se a proporção de `adverse_effects` difere significativamente entre os grupos `trx` para saber se o medicamento farmacêutico gerou efeitos colaterais estatisticamente significativos. *Dica: obtenha a contagem de sucessos e o total e faça um teste-z de proporções para as duas amostras.*
- 2) Associação entre efeitos adversos e os grupos: Teste se `num_effects` e `trx` são independentes para determinar se `trx` influencia o número de efeitos. *Dica: use um teste de independência qui-quadrado.*
- 3) Verificando se `age` é normalmente distribuída: Para decidir qual teste usar para confirmar se `age` difere significativamente entre os grupos `trx`, você precisa checar se `age` é normalmente distribuída nos grupos `trx`. Isso pode ser feito visualmente ou com um teste estatístico. *Dica: use um histograma e teste normalidade.*
- 4) Diferença significativa entre as idades dos dois grupos: Para garantir que `age` não foi um fator de confusão, faça um teste de Mann-Whitney para verificar se `age` difere significativamente entre os grupos `trx`. *Dica: use um teste U de Mann-Whitney.*

Sugestão de bibliotecas a serem usadas

```
# dados
import numpy as np
import pandas as pd
#testes estatísticos
from statsmodels.stats.proportion import proportions_ztest
import pingouin
#gráficos
import seaborn as sns
import matplotlib.pyplot as plt
```

Projeto 2: Análise de Partidas de Futebol Masculino e Feminino

Você trabalha como estagiário de dados para o setor de jornalismo esportivo em um grande portal online, especializado em análises e reportagens de futebol. O departamento acompanha partidas internacionais de futebol masculino e feminino há anos e tem a sensação de que há mais gols nos jogos internacionais femininos do que nos masculinos. Isso daria uma matéria investigativa interessante que os assinantes certamente vão adorar, mas seu chefe afirmou que você precisa fazer um teste de hipótese estatístico válido para ter certeza!

Ao definir o escopo do projeto, você reconhece que o esporte mudou muito ao longo dos anos, e o desempenho provavelmente varia bastante conforme o torneio. Por isso, decide limitar os dados da análise apenas às partidas oficiais da FIFA World Cup (sem incluir eliminatórias) desde 2002-01-01.

Você cria dois conjuntos de dados com os resultados de todas as partidas internacionais oficiais de futebol masculino e feminino desde o século XIX, obtidos por raspagem de uma fonte online confiável. Esses dados estão armazenados em dois arquivos CSV: `women_results.csv` e `men_results.csv`.

A pergunta que você quer responder é:

“Há mais gols nas partidas internacionais de futebol feminino do que nas de futebol masculino?”

Você assume um *nível de significância de 10%* e utiliza as seguintes hipóteses nula e alternativa:

- H_0 : O número médio de gols marcados nas partidas internacionais de futebol feminino é igual ao do masculino.
- H_A : O número médio de gols marcados nas partidas internacionais de futebol feminino é maior do que o do masculino.

Instruções

- 1) Realize um teste de hipótese apropriado para determinar o p-valor e, assim, o resultado de rejeitar ou não rejeitar a hipótese nula de que o número médio de gols marcados em partidas internacionais femininas é o mesmo que em partidas masculinas. Use um nível de significância de 10%.
- 2) Para esta análise, use partidas oficiais da FIFA World Cup desde 2002-01-01, e assuma também que cada partida é totalmente independente, ou seja, o momento/forma do time é ignorado.
- 3) O p-valor e o resultado do teste devem ser armazenados em um dicionário chamado `result_dict` no formato:

```
a) result_dict = {"p_val": p_val, "result": result}
```

onde `p_val` é o p-valor e `result` é a string *"fail to reject"* ou *"reject"*, dependendo do resultado do teste.

Como abordar o projeto

- 1) Análise exploratória de dados: carregue os dados de `men_results.csv` e `women_results.csv` para entender seu conteúdo a partir de uma análise exploratória dos dados. Lembre de filtrar os dados para incluir apenas partidas oficiais da FIFA World Cup que ocorreram depois de 2002-01-01.
- 2) Escolhendo o teste de hipótese correto:
 - a) Como há dois grupos independentes, masculino e feminino, esse cenário requer um teste bicaudal de duas amostras não pareadas.
 - b) Um teste t não pareado e um teste de Wilcoxon-Mann-Whitney são os dois testes de duas amostras mais comuns; o Wilcoxon-Mann-Whitney é a versão não paramétrica do teste t não pareado.
 - c) Para decidir entre um teste paramétrico ou não paramétrico, você precisa verificar os pressupostos dos testes paramétricos, incluindo checar o tamanho da amostra em cada grupo e a normalidade de cada distribuição.
 - d) Para testar normalidade:
 - Traçar um histograma mostrando a distribuição do número de gols marcados em partidas masculinas e femininas vai te dar uma ideia se o conjunto de dados é normalmente distribuído ou não.
 - Você pode rodar um teste de normalidade, como Kolmogorov-Smirnov ou Shapiro-Wilk.
- 3) Executando o teste de hipóteses: executar o teste e interpretar o p-value para determinar se há significância estatística entre os dois grupos, assumindo um nível de significância de 10%. *Dica: Se o p-value for menor ou igual ao nível de significância de 10% (0.1), rejeite a hipótese nula; caso contrário, não rejeite.*

Sugestão de bibliotecas a serem usadas

```
import pandas as pd
import matplotlib.pyplot as plt
import pingouin
from scipy.stats import mannwhitneyu
```